

ESPORTAZIONE PDF DI UNA CHAT CONDIVISA

Martina: XGBoost e PLS-SEM

Modello metodologico per startup, crescita del fatturato, open innovation e risorse tecnologiche

Fonte: <https://chatgpt.com/share/6a731302-7244-83ed-b05e-bc30b03ecb8d>

Data di esportazione: 5 agosto 2026

Formato: trascrizione pulita e impaginata

La pagina condivisa contiene anche metadati, versioni tecniche e passaggi non visibili nell'interfaccia. Questa esportazione conserva la sequenza e il contenuto sostanziale dei messaggi visibili, normalizzando refusi e formattazione. Sono esclusi messaggi di sistema, ragionamenti interni, chiamate a strumenti e contenuto integrale degli allegati.

Trascrizione

UTENTE

Ti ho messo questo materiale per un articolo che dobbiamo scrivere relativo a una ricerca che stiamo facendo. Io ora dovrei concentrarmi sulla creazione del modello matematico e sull'applicazione di XGBoost, mentre Carlo si occuperà della fuzzy.

Allegati indicati nella chat:

Framework metodologico Carlo Giglio.docx

Revenue_Growth_in_Tourism_Startup.pdf

Versione evidenziata_q_it_REV2 (1).pdf

Conceptual Model (1).pptx

Conceptual Model_Data_Carlo (2).pptx

CHATGPT

Ho letto il materiale caricato e lo schema è abbastanza chiaro: tu puoi coprire la parte predittiva e prescrittiva, mentre Carlo sviluppa la parte configurazionale con fsQCA/fuzzy.

C'è però un punto metodologico da chiarire nel paper: nei file compare sia **CB-SEM** sia **PLS-SEM**. Va scelta una linea coerente. Considerando la natura esplorativa del modello, la numerosità campionaria e l'obiettivo di integrare previsione e configurazioni, la sequenza più difendibile è:

PLS-SEM -> fsQCA -> XGBoost -> Operations Research / Optimization

Ruolo dei quattro blocchi

- **PLS-SEM:** stima le relazioni teoriche tra open innovation, risorse tecnologiche, innovativeness e crescita del fatturato.
- **fsQCA:** individua configurazioni alternative sufficienti per ottenere alta crescita, evidenziando equifinalità e complessità causale.
- **XGBoost:** costruisce il modello predittivo della probabilità di alta crescita e misura l'importanza delle variabili.
- **Ottimizzazione:** usa la previsione di XGBoost come funzione obiettivo e le configurazioni fsQCA come scenari o vincoli di ammissibilità.

Variabili da usare per la parte predittiva

Blocco	Variabili
Outcome	Revenue Growth = Q4_2
Open Innovation	proxy e costrutti derivati da Q13, verificando l'eventuale inversione della scala
Innovativeness	indicatori Q12
Technological Resources	indicatori Q14
Sottocategorie tecnologiche	Advanced ICT, Industry 5.0, Green Technologies
Controlli	dimensione, settore turismo, eventualmente età aziendale e accesso a finanziamenti

Nel questionario, Q4_2 descrive la crescita del fatturato con quattro livelli: riduzione, stabilità, crescita inferiore al 30%, crescita almeno pari al 30%.

Blocco da aggiungere al conceptual framework

OPTIMIZATION / OPERATIONS RESEARCH MODEL
XGBoost-based objective function
fsQCA-based scenario constraints
Budget, capacity, and firm-profile constraints
Optimal allocation of innovation and technology investments

UTENTE

Ok, ora fammi un esempio numerico considerando tutto quello che dobbiamo fare.

CHATGPT

Costruiamo un esempio piccolo ma completo, con numeri inventati esclusivamente per comprendere il meccanismo.

1. PLS-SEM: parte esplicativa

Supponiamo che il modello teorico stimi gli effetti di open innovation e delle risorse tecnologiche sull'innovativeness, e successivamente dell'innovativeness sulla crescita del fatturato. Il risultato potrebbe mostrare effetti diretti deboli di alcune risorse tecnologiche sulla crescita, ma effetti indiretti più rilevanti attraverso l'innovativeness.

$$\text{Innovativeness} = g(\text{Open Innovation, ICT, Industry 5.0, Green Technology})$$

$$\text{Revenue Growth} = h(\text{Innovativeness, Open Innovation, Technology, Firm Size})$$

Questo blocco serve a verificare il modello teorico, non a produrre la migliore previsione possibile.

2. XGBoost: parte predittiva

Sulle osservazioni delle startup si addestra un classificatore che restituisce, per ciascuna impresa, la probabilità di appartenere alla classe di alta crescita:

$$\hat{p}(i) = P(Q4_2 = 4 \mid X(i))$$

I predittori comprendono innovativeness, pratiche di open innovation, risorse tecnologiche e variabili di controllo. Il modello può rilevare relazioni non lineari e interazioni che non emergono dalla sola analisi strutturale.

3. fsQCA: parte configurazionale

La fsQCA può restituire, per esempio, più "ricette" compatibili con alta crescita:

- elevata innovativeness + Advanced ICT + open innovation manageriale;

- Industry 5.0 + collaborazione ecosistemica + dimensione adeguata;
- green technology + innovazione sociale + accesso a risorse finanziarie.

Le configurazioni non sono coefficienti marginali: indicano combinazioni di condizioni con sufficienza empirica per l'esito.

4. Modello di ottimizzazione

La funzione obiettivo massimizza la probabilità di alta crescita stimata da XGBoost:

$$\max(x) f_XGB(x)$$

soggetta a:

- vincolo di budget;
- vincoli di capacità organizzativa;
- profilo dell'impresa, che non può essere modificato arbitrariamente;
- coerenza con almeno una configurazione di successo individuata dalla fsQCA.

Il risultato non è soltanto "quale variabile conta di più", ma quale combinazione di investimenti e pratiche sia più promettente per uno specifico profilo aziendale.

UTENTE

Come dobbiamo considerare la dimensione aziendale e le diverse categorie tecnologiche?

CHATGPT

La **firm size** va trattata principalmente come variabile di controllo o di scenario, non come una leva decisionale liberamente ottimizzabile. Nel modello prescrittivo si può fissare il profilo dell'impresa e cercare la strategia migliore compatibile con quel profilo.

Le categorie tecnologiche vanno mantenute separate perché rappresentano risorse differenti:

- **Tech_ICT:** AI, cloud/big data, cybersecurity;
- **Tech_I5.0:** robotics, IoT, blockchain, micro- e nanoelettronica;
- **Tech_Green:** tecnologie green e clean.

Q12 rappresenta l'innovativeness, Q14 l'adozione di tecnologie avanzate e Q4_2 la crescita del fatturato.

UTENTE

Come posso formulare il modello matematico in inglese?

CHATGPT

Una formulazione sintetica e adatta al paper è:

In this case, expected revenue growth is expressed as a function of innovativeness, open innovation practices, technological resources, and firm size. Innovativeness is itself modeled as a function of open innovation and the three technological resource categories.

In forma simbolica:

$$E[\text{Revenue Growth}] = F(\text{INN}, \text{OI}, \text{Tech_ICT}, \text{Tech_I5.0}, \text{Tech_Green}, \text{Size})$$

$$\text{INN} = G(\text{OI}, \text{Tech_ICT}, \text{Tech_I5.0}, \text{Tech_Green})$$

Per la parte predittiva, la formulazione più precisa è:

$$\hat{p} = f_XGB(\text{OI}, \text{INN}, \text{Tech_ICT}, \text{Tech_I5.0}, \text{Tech_Green}, \text{Size}, \text{Controls})$$

UTENTE

Non mi è ancora chiaro come entra la fsQCA nel modello prescrittivo.

CHATGPT

Il collegamento va spiegato distinguendo previsione e ammissibilità.

XGBoost assegna un punteggio a ogni possibile combinazione di condizioni: più precisamente, stima la probabilità di alta crescita. **fsQCA**, invece, identifica le configurazioni osservate che risultano sufficientemente coerenti con l'alta crescita.

Nel modello di ottimizzazione:

- la probabilità prevista da XGBoost diventa la funzione obiettivo;
- le ricette fsQCA diventano vincoli logici o scenari strategici;
- budget, capacità e caratteristiche dell'impresa completano l'insieme dei vincoli.

$$\max(x) f_XGB(x), \text{ subject to } x \text{ in } \Omega_{fsQCA} \text{ and operational constraints}$$

Testo utilizzabile nel paper:

The insights generated by the explanatory, configurational, and predictive analyses are integrated into a prescriptive decision-support layer. The XGBoost-estimated probability of high revenue growth is used as the objective function, while the empirically sufficient configurations identified through fsQCA are translated into scenario-based feasibility constraints. In this way, the model identifies strategic combinations of open innovation and technological investments that are both predictively effective and configurationally consistent with empirical success recipes.

In italiano: il modello usa la probabilità di alta crescita stimata da XGBoost come funzione obiettivo, mentre le configurazioni individuate dalla fsQCA vengono incorporate come vincoli o scenari di ammissibilità.

UTENTE

Per XGBoost dobbiamo impostare una classificazione oppure una regressione?

CHATGPT

La scelta più coerente per il modello principale è una **classificazione binaria**.

Si può definire:

$$\text{HighGrowth} = 1 \text{ se } Q4_2 = 4; \text{ HighGrowth} = 0 \text{ altrimenti}$$

e stimare:

$$p\text{-hat}(i) = P(Q4_2 = 4 \mid X(i))$$

Questa probabilità è immediatamente utilizzabile nell'ottimizzazione. La scala originaria a quattro categorie non è una variabile continua: una regressione standard imporrebbe distanze numeriche non giustificate tra riduzione, stabilità, crescita inferiore al 30% e crescita almeno pari al 30%.

Robustness check

Le quattro categorie originarie vanno comunque conservate per verifiche di robustezza:

$$1 = \text{riduzione}; 2 = \text{stabilità}; 3 = <30\%; 4 = \geq 30\%$$

- modello principale: classificazione binaria;
- controllo: classificazione multiclasse;
- controllo alternativo: modello ordinale o regressione logistica ordinale.

L'obiettivo è verificare se le variabili più rilevanti e le conclusioni generali rimangono stabili.

UTENTE

Ora ti do il dataset che ho a disposizione. La nostra analisi deve coinvolgere solo le startup.

Nel file gli item di alcuni costrutti sono stati raggruppati nelle colonne evidenziate in rosso. La colonna AG, denominata "startups", indica con 0 le aziende non startup e con 1 tutte le startup, che dovrebbero essere circa 311.

I costrutti principali sono:

- **Innovativeness:** product-service, process-organization, social purposes;
- **Open innovation practices:** managerial/organizational, technological, ecosystem-level, financial;
- **Technologies:** Advanced ICT, Industry 5.0, Green technologies;
- **Revenue growth:** Q4_2, misurata con un singolo item.

CHATGPT

Il filtro sulla colonna `AG = 1` restituisce **311 startup complessive**. Tuttavia, il controllo del codice settoriale mostra che soltanto **21** hanno il settore turismo identificato con `d1b = 14`.

Quindi non è corretto descrivere il campione come "311 tourism startups". La formulazione corretta è **analysis of startups**, specificando che il dataset comprende startup appartenenti a più settori.

Il turismo può essere:

- una variabile di controllo binaria;
- un'analisi di sottogruppo esplorativa;
- un elemento di discussione settoriale.

Con sole 21 osservazioni turistiche, non è prudente stimare un XGBoost affidabile esclusivamente su quel sottocampione, né applicare l'intero framework senza forti cautele.

Tabella analitica prevista

Dopo la gestione dei mancanti, la tabella potrebbe contenere circa 301 osservazioni complete, con 11 predittori e un target. Il numero effettivo va verificato prima di qualsiasi modellazione.

UTENTE

Come dobbiamo procedere concretamente con l'analisi?

CHATGPT

Passaggio 1 - Definire il campione

Filtrare `AG = 1`, documentare il numero iniziale di startup e il numero finale dopo l'esclusione dei casi incompleti. Non eliminare osservazioni senza riportarne il motivo.

Passaggio 2 - Costruire il dizionario delle variabili

Per ogni predittore indicare: nome nel dataset, costruito teorico, scala, direzione, eventuale inversione, metodo di aggregazione degli item e percentuale di dati mancanti.

Passaggio 3 - Validare i costrutti aggregati

Verificare che le colonne rosse siano state calcolate correttamente e che item con formulazione inversa siano stati ricodificati prima della media o del punteggio composito.

Passaggio 4 - Definire il target

Creare il target principale:

$$\text{HighGrowth} = 1 \text{ se } Q4_2 = 4, \text{ altrimenti } 0$$

Controllare la distribuzione delle classi. Se la classe positiva è molto rara, usare metriche e pesi appropriati, senza ricorrere automaticamente a oversampling prima di aver impostato correttamente la cross-validation.

Passaggio 5 - Analisi descrittiva e qualità dei dati

- conteggio delle osservazioni;
- distribuzione del target;
- valori mancanti;
- statistiche descrittive;
- range e codici anomali;
- correlazioni e ridondanze tra predittori.

Finché questo passaggio non è validato, non conviene eseguire né la regressione logistica né XGBoost.

Passaggio 6 - Modello baseline

Stimare una regressione logistica semplice sullo stesso target e sugli stessi predittori. La baseline serve a dimostrare se XGBoost produce un miglioramento reale rispetto a un modello interpretabile e parsimonioso.

Passaggio 7 - Strategia di validazione

Usare cross-validation stratificata. Tutte le operazioni che apprendono dai dati - imputazione, selezione, bilanciamento e tuning - devono essere effettuate all'interno dei fold per evitare data leakage.

Passaggio 8 - Addestramento e tuning di XGBoost

I principali iperparametri da esplorare sono:

- `n_estimators`
- `max_depth`
- `learning_rate`
- `subsample`
- `colsample_bytree`
- `min_child_weight`
- `reg_alpha`
- `reg_lambda`

Con circa 300 osservazioni è preferibile evitare alberi profondi. Configurazioni illustrative da confrontare:

Configurazione	n_estimators	max_depth	learning_rate
A	100	2	0,10
B	300	3	0,05
C	500	5	0,02

Questi valori sono punti di partenza, non risultati da scegliere a priori. Il tuning va effettuato all'interno della validazione.

Passaggio 9 - Metriche

Riportare almeno ROC-AUC, precision, recall, F1-score, matrice di confusione e, se la classe è sbilanciata, PR-AUC. Per usare le probabilità nel modello prescrittivo è importante verificare anche la calibrazione.

Passaggio 10 - Interpretabilità

Analizzare importanza delle feature, effetti marginali e SHAP values. L'obiettivo è capire quali variabili guidano le previsioni e se gli effetti sono coerenti con PLS-SEM e fsQCA. Vanno mostrati anche alcuni casi rappresentativi.

Passaggio 11 - Robustness check

Confrontare il modello binario con la classificazione multiclasse e con un modello ordinale. Non è necessario ottenere le stesse metriche: serve verificare la stabilità delle variabili più importanti e delle conclusioni.

Passaggio 12 - Collegamento con fsQCA e Operations Research

La fsQCA restituirà configurazioni del tipo:

$C(k) \rightarrow \text{HighGrowth}$

XGBoost restituirà:

$f_{\text{XGB}}(x) = P(\text{HighGrowth} = 1)$

Il modello OR utilizzerà:

$\max(x) f_{\text{XGB}}(x)$

soggetto a:

$x \in \Omega_{\text{fsQCA}}$

e ai vincoli di budget, capacità e profilo aziendale.

Primo output operativo

Il primo risultato da produrre non è ancora il modello XGBoost, ma un pacchetto di validazione composto da:

- conteggio delle osservazioni;
- distribuzione del target;
- dizionario delle variabili;
- tabella dei valori mancanti;
- statistiche descrittive dei predittori;
- controllo dei codici anomali.

CHATGPT - SINTESI CONCLUSIVA DELLA CHAT

La logica complessiva dell'articolo può essere presentata come un'integrazione di quattro prospettive complementari:

1. **spiegazione teorica** con PLS-SEM;
2. **configurazioni causali** con fsQCA;
3. **previsione individuale** con XGBoost;
4. **supporto alle decisioni** con un modello di ottimizzazione.

Il contributo distintivo non consiste semplicemente nell'applicare più tecniche allo stesso dataset, ma nell'assegnare a ciascuna tecnica una funzione precisa e nel collegarne formalmente gli output.